

EFREI PARIS — ANNÉE 2025-2026

Conception et implémentation d'un Data Lake d'analyse de sentiment

Data Lakes & Data Integration — Projet final

Auteur : Adem Mamouni

Spécialité : Big Data & Machine Learning (4^e année)

Encadrant : Yvann Vincent

Niveau traité : Standard + Avancé

MinIO (S3)

Elasticsearch

Apache Airflow

FastAPI

RoBERTa

Docker Compose

Sommaire

1. Introduction et objectifs

2. Choix fonctionnels : domaine et sources de données

3. Architecture de la solution

4. Implémentation des trois zones

5. Composante Machine Learning / Deep Learning

6. Orchestration avec Apache Airflow

7. API Gateway

8. Niveau avancé : `/ingest` et `/ingest_fast`

9. Difficultés rencontrées et résolues

10. Limites et perspectives

11. Conclusion

Annexe A — Procédure d'installation et de build

Annexe B — Structure du dépôt

1. Introduction et objectifs

1.1 Contexte

Ce projet consiste à concevoir et implémenter un *data lake* complet, de l'ingestion des données jusqu'à leur exposition via une API. L'exercice couvre l'ensemble de la chaîne de valeur d'une plateforme de données moderne : acquisition de sources hétérogènes, raffinage progressif, orchestration reproductible et mise à disposition.

Au-delà des exigences fonctionnelles, l'objectif que nous nous sommes fixé est de produire une solution qui tienne les standards d'un environnement de production : configuration externalisée, gestion d'erreurs explicite, reproductibilité par conteneurisation, et surtout **décisions techniques fondées sur la mesure plutôt que sur l'intuition**. Cette exigence méthodologique constitue le fil conducteur du présent rapport.

1.2 Périmètre traité

Le **niveau standard** et le **niveau avancé** ont tous deux été implémentés et validés.

Exigence du sujet	Statut	Réalisation
Data lake en zones distinctes	Traité	Architecture RAW / STAGING / CURATED
Zone RAW en S3 ou Elasticsearch	Traité	MinIO, stockage objet compatible S3
Deux sources (fichier + API)	Traité	Dataset HuggingFace + API Hacker News
Pipelines de transformation	Traité	RAW→STAGING et STAGING→CURATED
Pipeline d'intégration (Airflow / DVC)	Traité	DAG Airflow, scheduling horaire, XCom
API Gateway (5 endpoints)	Traité	9 endpoints exposés
Intégration ML / Deep Learning	Traité	Transformer RoBERTa (75,6 % de précision)
[Avancé] /ingest et /ingest_fast (≥ 30 %)	Traité	Jusqu'à +83,2 % (×6,0)

2. Choix fonctionnels : domaine et sources

2.1 Domaine applicatif retenu

Le sujet laissant une liberté totale sur le choix des données, nous avons retenu l'**analyse de sentiment de texte social** (NLP). Trois raisons ont motivé ce choix :

- **Pertinence de la donnée non structurée.** Le texte brut est l'archétype de la donnée qu'un data lake sait valoriser et qu'un entrepôt traditionnel gère mal.
- **Adéquation avec la zone curated.** Le texte enrichi appelle naturellement un moteur de recherche et d'agrégation, ce qui justifie un choix technologique fort plutôt qu'un SGBD par défaut.
- **Support d'une composante Deep Learning.** Le domaine permet d'intégrer un modèle Transformer, explicitement valorisé par le sujet.

2.2 Les deux sources

	Source API	Source fichier
Fournisseur	Hacker News (API Firebase publique)	HuggingFace — <code>cardiffnlp/tweet_eval</code>
Nature	Posts technologiques en temps réel	Tweets annotés en sentiment
Volume par cycle	50 posts	500 textes
Intérêt	Flux vivant, justifie le scheduling	Fournit une vérité terrain

DÉCISION DE CONCEPTION

Le dataset HuggingFace conserve son **label d'origine** (`true_label`) tout au long du pipeline. Ce choix, en apparence anodin, permet au data lake de **s'auto-évaluer** : à chaque exécution, la précision du modèle est recalculée en confrontant ses prédictions à la vérité terrain. La qualité devient une métrique surveillée, et non une hypothèse.

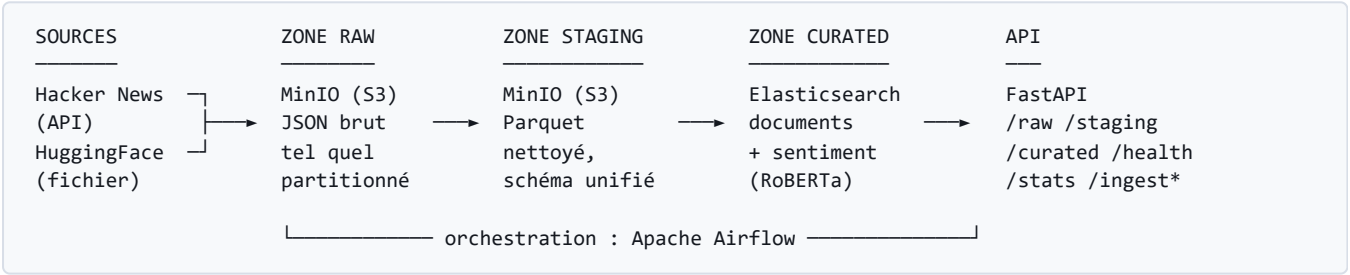
INCIDENT : FERMETURE DE L'API REDDIT

La source API initialement retenue était Reddit. En cours de projet, la plateforme a fermé la création d'applications *legacy*, rendant l'obtention de clés impossible. La couche d'ingestion ayant été conçue pour **découpler la source du reste du pipeline**, la bascule vers Hacker News n'a nécessité la modification que d'un **unique fichier** ; l'architecture, les transformations, l'orchestration et l'API sont restées inchangées. Cet incident valide a posteriori la pertinence du découplage.

3. Architecture de la solution

3.1 Vue d'ensemble

Nous avons retenu l'architecture classique en trois zones (*medallion* : bronze / argent / or), chacune assumant une responsabilité unique et clairement délimitée.



3.2 Justification des choix technologiques

Zone	Technologie	Justification
RAW	MinIO (S3)	Satisfait la contrainte du sujet (S3 ou Elasticsearch). MinIO implémente l'API S3 à l'identique : le code écrit ici fonctionnerait sur AWS S3 sans modification , seule l'adresse du point d'entrée changeant. Coût nul, exécution locale.
STAGING	Parquet sur MinIO	Format orienté colonne : compression nettement supérieure au JSON et lectures analytiques accélérées (possibilité de ne lire qu'une colonne). C'est le format de référence de la donnée analytique.
CURATED	Elasticsearch	Le domaine étant textuel, la zone finale doit servir deux usages : recherche full-text (index inversé) et agrégations (sentiment moyen par source, distributions). Elasticsearch répond aux deux en une seule requête, là où un SGBD relationnel serait inadapté au premier.

3.3 Infrastructure

L'intégralité de la solution est décrite dans un unique fichier `docker-compose.yml` : une seule commande (`docker compose up -d --build`) démarre les sept services. Cette conteneurisation garantit la **reproductibilité** : la solution se comporte de façon identique sur n'importe quel poste.

projetdatalake
C:\Users\ademm\Desktop\Projet DataLake

api ● datalake/api:1.0.0 8000:8000 ↗		
airflow-sched... ● datalake/airflow:2		
airflow-webs... ● datalake/airflow:2 8080:8080 ↗		
airflow-init ○ datalake/airflow:2		
createbuckets ○ minio/mc:latest		
postgres ● postgres:13		
minio ● minio/minio:latest 9000:9000 ↗ Show all ports (2)		
elasticsearch ● elasticsearch/elas 9200:9200 ↗		

airflow-webserver
airflow-scheduler

Figure 1 — Les services de la stack : API, Airflow (scheduler, webserver, init), Postgres, MinIO et Elasticsearch, tous opérationnels.

4. Implémentation des trois zones

4.1 Zone RAW — la donnée brute comme source de vérité

La zone RAW applique une règle stricte : **la donnée brute n'est jamais modifiée**. Elle est stockée telle que la source la fournit, accompagnée d'une simple enveloppe de métadonnées d'ingestion (source, horodatage, volume). Cette discipline garantit que toute zone en aval reste **entièrement reconstituable** : si la logique de nettoyage évolue, il suffit de rejouer le pipeline depuis le brut.

Les objets sont **partitionnés par source puis par date**. Le partitionnement rend le lac navigable et autorise le re-traitement ciblé d'une journée précise sans relire l'intégralité du volume.




Figure 2 — Bucket `raw` (1 006 objets) : partitionnement de premier niveau par source (`hackernews` , `huggingface` , `api` pour les ingestions à la demande).




Figure 3 — Partitionnement de second niveau par date, alimenté automatiquement par le scheduling Airflow.

raw / hackernews / 2026-07-08			Create new path
☐	Name	Last Modified	Size
☐	20260708T191553_topstories.json	Wed, Jul 08 2026 21:15 (GMT+2)	40.9 KiB

Figure 4 — Fichier brut horodaté, contenant le payload JSON intact renvoyé par l'API.

4.2 Zone STAGING — nettoyage et unification des schémas

C'est l'étape d'**intégration** à proprement parler, et le cœur de la problématique posée par le sujet. Un post Hacker News (`{id, title, by, score, time}`) et un tweet (`{text, label}`) n'ont aucune structure commune. Un **normaliseur par source**, sélectionné par un aiguillage sur le préfixe de la clé S3, projette chaque enregistrement vers un **schéma unique** :

Colonne	Description
<code>id</code>	Identifiant unique et déterministe
<code>source</code>	<code>hackernews</code> <code>huggingface</code> <code>api</code>
<code>text</code> / <code>text_clean</code>	Texte d'origine / texte nettoyé
<code>true_label</code>	Vérité terrain (dataset annoté uniquement)
<code>created_at</code> , <code>ingested_at</code>	Horodatages normalisés en ISO 8601

UN NETTOYAGE VOLONTAIREMENT CONSERVATEUR

La fonction de nettoyage décode les entités HTML, retire les balises et les URLs, puis normalise les espaces. En revanche, elle **ne met pas le texte en minuscules et conserve la ponctuation**. Ce n'est pas un oubli : les modèles de sentiment exploitent les majuscules (emphase) et la ponctuation répétée comme signaux d'intensité. Un nettoyage plus agressif *dégraderait* la qualité en aval. Le bon prétraitement dépend toujours du traitement qui le suit.

Deux garde-fous de robustesse complètent le pipeline : un **dédoublonnage** sur l'identifiant (une ré-ingestion ne duplique pas les données) et l'élimination des enregistrements devenus vides après nettoyage.

staging		Rewind	Refresh	Upload
Created on: Wed, Jul 08 2026 21:08:09 (GMT+2) Access: PRIVATE 1.4 MiB - 11 Objects				
staging / 2026-07-08				
☐	Name	Last Modified	Size	
☐	part-20260708T192052.parquet	Wed, Jul 08 2026 21:20 (GMT+2)	99.1 KiB	

Figure 5 — Zone STAGING : instantanés Parquet compressés (Snappy), partitionnés par date.

4.3 Zone CURATED — enrichissement et indexation

Le dernier pipeline calcule le sentiment de chaque texte, puis indexe les documents enrichis dans Elasticsearch. L'indexation utilise l'identifiant métier comme `_id` du document, ce qui rend l'opération **idempotente** : rejouer le pipeline met à jour les documents existants au lieu de créer des doublons — propriété indispensable pour une chaîne exécutée toutes les heures.

5. Composante Machine Learning / Deep Learning

5.1 Une première approche insuffisante : VADER

Le premier moteur implémenté fut **VADER**, un modèle à base de lexique et de règles, conçu pour le texte social. Rapide et déterministe, il présente néanmoins une précision décevante de **52,8 %** sur nos 500 textes annotés — à peine au-dessus d'une classification naïve.

Plutôt que d'accepter ce chiffre, nous avons **diagnostiqué** en construisant la matrice de confusion :

Classe	Vérité terrain	Prédictions VADER	Diagnostic
neutral	217	143	fortement sous-prédite
positive	200	246	sur-prédite
negative	83	111	sur-prédite

Le modèle bascule trop facilement hors du neutre : ses seuils par défaut ($\pm 0,05$) sont trop étroits. Un élargissement de la bande neutre porte la précision à 58,6 %, mais nous avons **rejeté ce résultat pour des raisons méthodologiques** : le seuil optimal avait été recherché sur les données mêmes qui servaient à l'évaluer, ce qui constitue un *surapprentissage* et produit un chiffre non généralisable. VADER reste conservé comme **baseline de comparaison**.

5.2 Le modèle retenu : Transformer RoBERTa

La limite de VADER est structurelle : un modèle lexical ne comprend ni le contexte, ni la négation complexe, ni le sarcasme. Nous avons donc intégré `cardiffnlp/twitter-roberta-base-sentiment-latest`, un Transformer RoBERTa pré-entraîné sur environ 124 millions de tweets puis spécialisé sur la tâche de sentiment à trois classes.

Moteur	Nature	Précision	Rappel par classe (nég. / neu. / pos.)
Baseline « tout neutre »	—	43,4 %	—
VADER	Lexique + règles	52,8 %	déséquilibré
RoBERTa	Transformer (Deep Learning)	75,6 %	0,77 / 0,76 / 0,75

LECTURE DES RÉSULTATS

Le gain de **+22,8 points** n'est pas le seul enseignement : le **rappel par classe est équilibré** (0,77 / 0,76 / 0,75). Le modèle ne sacrifie aucune classe pour gonfler sa précision globale — un piège fréquent que seule une métrique désagrégée permet de détecter.

Le moteur est **pilotable par configuration** (`SENTIMENT_ENGINE=transformer|vader`), ce qui permet de basculer entre les deux sans modifier une ligne de code des pipelines.

6. Orchestration avec Apache Airflow

6.1 Structure du DAG

Airflow a été préféré à DVC car il apporte, en plus de la reproductibilité, le **scheduling** requis pour ingérer l'API à intervalle régulier ainsi qu'une interface de supervision — un profil bien plus proche d'un usage de production.

Le DAG `datalake_pipeline` enchaîne cinq tâches. Les deux ingestions, indépendantes, s'exécutent **en parallèle** ; la transformation attend leur convergence (*fan-in*).




Figure 6 — Graphe du DAG : parallélisation des deux ingestions, puis chaîne de raffinage séquentielle. Le scheduling horaire est visible en haut à droite.

6.2 Fiabilité et communication inter-tâches

- **Scheduling horaire** : le lac s'alimente en continu depuis l'API, sans intervention.
- **Reprise sur erreur** : chaque tâche dispose de `retries=2` et d'un `execution_timeout`, afin d'absorber une indisponibilité transitoire de l'API.
- **XCom** : la tâche `report` récupère les valeurs de retour des tâches amont pour produire une synthèse de cycle, incluant les métriques de qualité du modèle.

POINT D'IMPLÉMENTATION

Les imports de notre code sont effectués **à l'intérieur des fonctions** et non en tête du fichier de DAG. Airflow ré-analyse en effet tous les fichiers de DAG toutes les trente secondes : importer PyTorch à chaque analyse saturerait le `scheduler`. Un fichier de DAG doit se parser en moins d'une seconde.




Figure 7 — Rapport de cycle construit à partir des XCom : volumes ingérés par source, dédoublement, distribution des sentiments et précision du modèle recalculée à chaque exécution.

PREUVE DU DÉDOUBLONNAGE

Ce rapport constitue une validation opérationnelle : après plusieurs cycles, la source HuggingFace reste stable à **500 textes** (identifiants déterministes, donc dédoublement), tandis que Hacker News croît à **180 posts** — les *top stories* ayant réellement changé entre les exécutions. Le comportement incrémental attendu est vérifié.




Figure 8 — Historique des exécutions. Les échecs initiaux (en rouge) correspondent aux incidents documentés en section 9, résolus depuis.

7. API Gateway

FastAPI a été retenu pour son asynchronisme natif, sa validation déclarative par Pydantic et sa documentation OpenAPI générée automatiquement. L'API expose **neuf endpoints** — les cinq exigés, complétés par quatre endpoints additionnels.

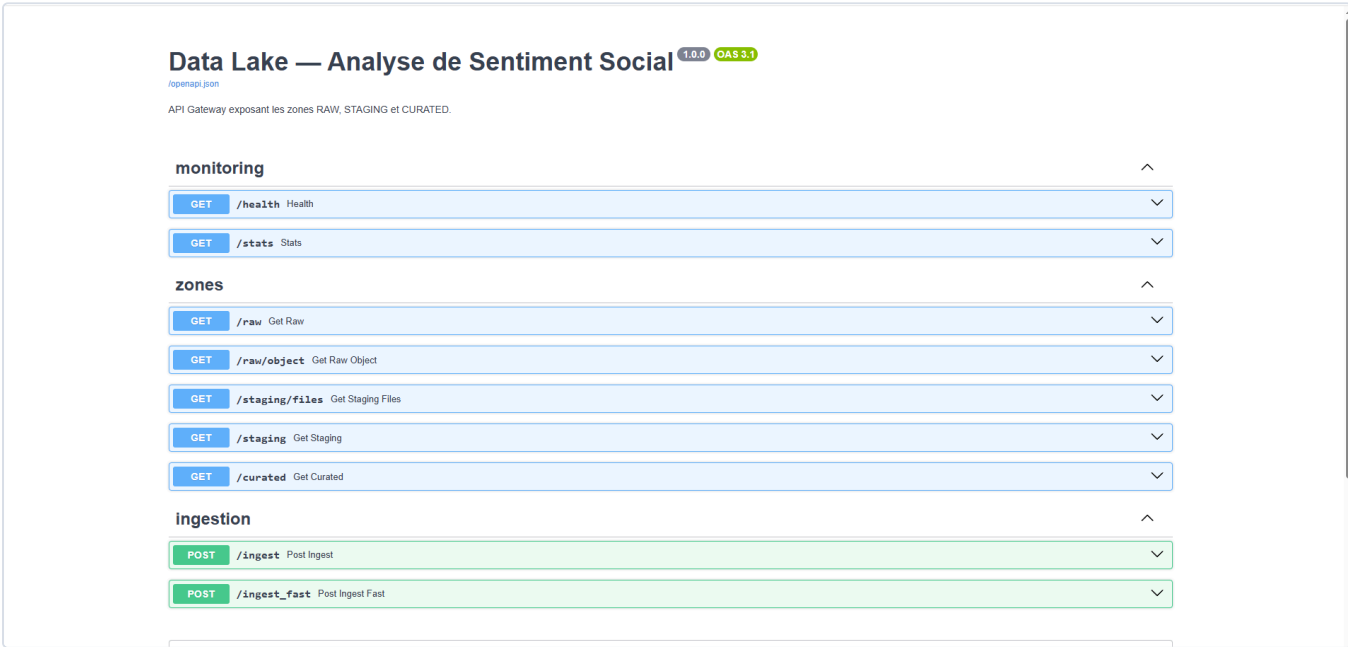


Figure 9 — Documentation OpenAPI auto-générée, regroupée par domaine fonctionnel : supervision, zones du lac, ingestion.

Endpoint	Rôle
GET /health	État des services ; renvoie 503 si un composant est injoignable
GET /stats	Volumétrie des trois zones : objets, octets, documents, distribution
GET /raw , /raw/object	Listing des objets bruts et lecture d'un objet
GET /staging , /staging/files	Lecture des instantanés Parquet, filtrable par source
GET /curated	Recherche full-text + filtres exacts + pagination
POST /ingest , /ingest_fast	[Avancé] Ingestion à la demande — voir section 8

7.1 Supervision : /health et /stats

L'endpoint `/health` respecte la convention attendue par les sondes d'infrastructure : le **code HTTP** porte le verdict (200 ou 503), et non uniquement le corps de la réponse.

GET /stats Slots

Volumétrie des trois zones : objets, octets, documents, sentiments.

Parameters
Cancel

No parameters

Exécuter Clear

Responses

Curl

```
curl -X 'GET' \
  'http://localhost:8080/stats' \
  -H 'accept: application/json'
```

Request URL

```
http://localhost:8080/stats
```

Server response

Code
Details

200

```
{
  "response_body": {
    "objects": 1000,
    "total_size_bytes": 1743308,
    "by_source": {
      "backrooms": 11,
      "huggingface": 11
    }
  },
  "staging": {
    "bucket": "staging",
    "objects": 11,
    "total_size_bytes": 1446048
  },
  "curated": {
    "index": "curated_sentiment",
    "documents": 1707,
    "size_bytes": 830758,
    "by_sentiment": {
      "positive": 643,
      "neutral": 573,
      "negative": 491
    },
    "by_source": {
      "api": 1027,
      "huggingface": 508,
      "backrooms": 180
    }
  }
}
```

Download

Response headers

```
content-length: 471
content-type: application/json
date: Sat, 11 Jul 2020 13:37:29 GMT
server: uvicorn
```

Response
Code
Description
Links

200
Successful Response
No links

Media type

application/json

Controls
Accept header
Example Value
Schema

```
"string"
```

Figure 10 — `/stats` : volumétrie consolidée des trois zones, avec ventilation par source et par sentiment obtenue via une agrégation Elasticsearch.

7.2 Exploitation : `/curated`

L'endpoint `/curated` combine une requête booléenne Elasticsearch (`must` pour le full-text scoré, `filter` pour les filtres exacts — ces derniers étant mis en cache par le moteur) avec une pagination.

GET /curated Get Curated

Interroge la zone CURATED : documents enrichis d'un score de sentiment.
Combine recherche full-text (`q`) et filtres exacts (`source` , `sentiment`).

Paramètres

Cancel

Name	Description
<code>q</code> string (string null) (query)	Recherche full-text dans le texte AI
<code>source</code> string (string null) (query)	Filtre : hackernews huggingface source
<code>sentiment</code> string (string null) (query)	Filtre : positive neutral negative negative
<code>limit</code> integer (query)	20 maximum: 200 minimum: 1
<code>offset</code> integer (query)	0 minimum: 0

Exécuter
Clear

Responses

Curl

```
curl -X 'GET' \
'http://localhost:8000/curated?q=AI&sentiment=negative&limit=20&offset=0' \
-H 'accept: application/json'
```

Request URL

```
http://localhost:8000/curated?q=AI&sentiment=negative&limit=20&offset=0
```

Server response

Code Details

200

Response body

```
{
  "id": "hn_48864390",
  "source": "hackernews",
  "author": "biayu",
  "text": "Guy is banned by OpenAI for cyber abuse, his AI appeals, another AI approves it",
  "text_class": "Guy is banned by OpenAI for cyber abuse, his AI appeals, another AI approves it",
  "true_label": null,
  "created_at": "2026-07-30T19:50:27+00:00",
  "ingested_at": "2026-07-10T21:00:02+00:00",
  "sentiment": "negative",
  "sentiment_score": -0.6888147163391113
},
{
  "id": "hn_48840620",
  "source": "hackernews",
  "author": "droidjj",
  "text": "What's slowing down the AI buildout",
  "text_class": "What's slowing down the AI buildout",
  "true_label": null,
  "created_at": "2026-07-09T03:26:03+00:00",
  "ingested_at": "2026-07-10T13:00:01.641204+00:00",
  "sentiment": "negative",
  "sentiment_score": -0.45682551626285464
},
{
  "id": "hn_48863707",
```

Response headers

```
content-length: 1237
content-type: application/json
date: Sat, 11 Jul 2026 13:38:54 GMT
server: uvicorn
```

Response raw

Figure 11 — Requête croisant recherche full-text (`q=AI`) et filtre de sentiment (`negative`). Les résultats sont sémantiquement cohérents : « Guy is banned by OpenAI for cyber abuse », « What's slowing down the AI buildout ».

7.3 Gestion des erreurs

Un soin particulier a été porté aux cas d'erreur, critère explicite d'évaluation. Les codes HTTP sont respectés et les messages sont **actionnables** :

Code	Situation	Message renvoyé
422	Valeur non valide	« <i>Sentiment invalide : 'heureux'. Valeurs acceptées : negative, neutral, positive.</i> »
404	Ressource inexistante	« <i>Aucun objet brut pour la source 'twitter'. Sources valides : hackernews, huggingface.</i> »
503	Service injoignable	Identification du composant défaillant (MinIO ou Elasticsearch)

8. Niveau avancé : /ingest et /ingest_fast

Le niveau avancé exige un endpoint d'ingestion propageant des textes à travers tout le pipeline, ainsi qu'une variante optimisée offrant au minimum **30 % de gain**. Les deux traversent l'intégralité de la chaîne : écriture en zone RAW, scoring, indexation en zone CURATED.

POST /ingest_fast Post Ingest Fast

Version optimisée de [/ingest](#) — résultat identique, débit très supérieur.

Optimisations : inférence par lots, indexation bulk Elasticsearch, écritures S3 parallèles recouvrant le calcul, [torch.inference_mode\(\)](#). Détail complet dans [src/api/ingest.py](#) et [docs/performance.md](#).

Parameters Cancel Reset

Name	Description
include_documents	Renvoyer tous les documents
boolean (query)	false

Request body required application/json

Edit Value | Schema

```
{
  "data": {
    "texts": [
      "J'aime trop la DATA !!!!!!!",
      "Par contre j'aime pas trop la cyber"
    ]
  }
}
```

Execute Clear

Responses

Curl

```
curl -X 'POST' \
  'http://localhost:8000/ingest_fast?include_documents=false' \
  -H 'accept: application/json' \
  -H 'Content-Type: application/json' \
  -d '{
    "data": {
      "texts": [
        "J'aime trop la DATA !!!!!!!",
        "Par contre j'aime pas trop la cyber"
      ]
    }
  }'
```

Figure 12 — `/ingest_fast` : structure JSON conforme à celle imposée par le sujet.

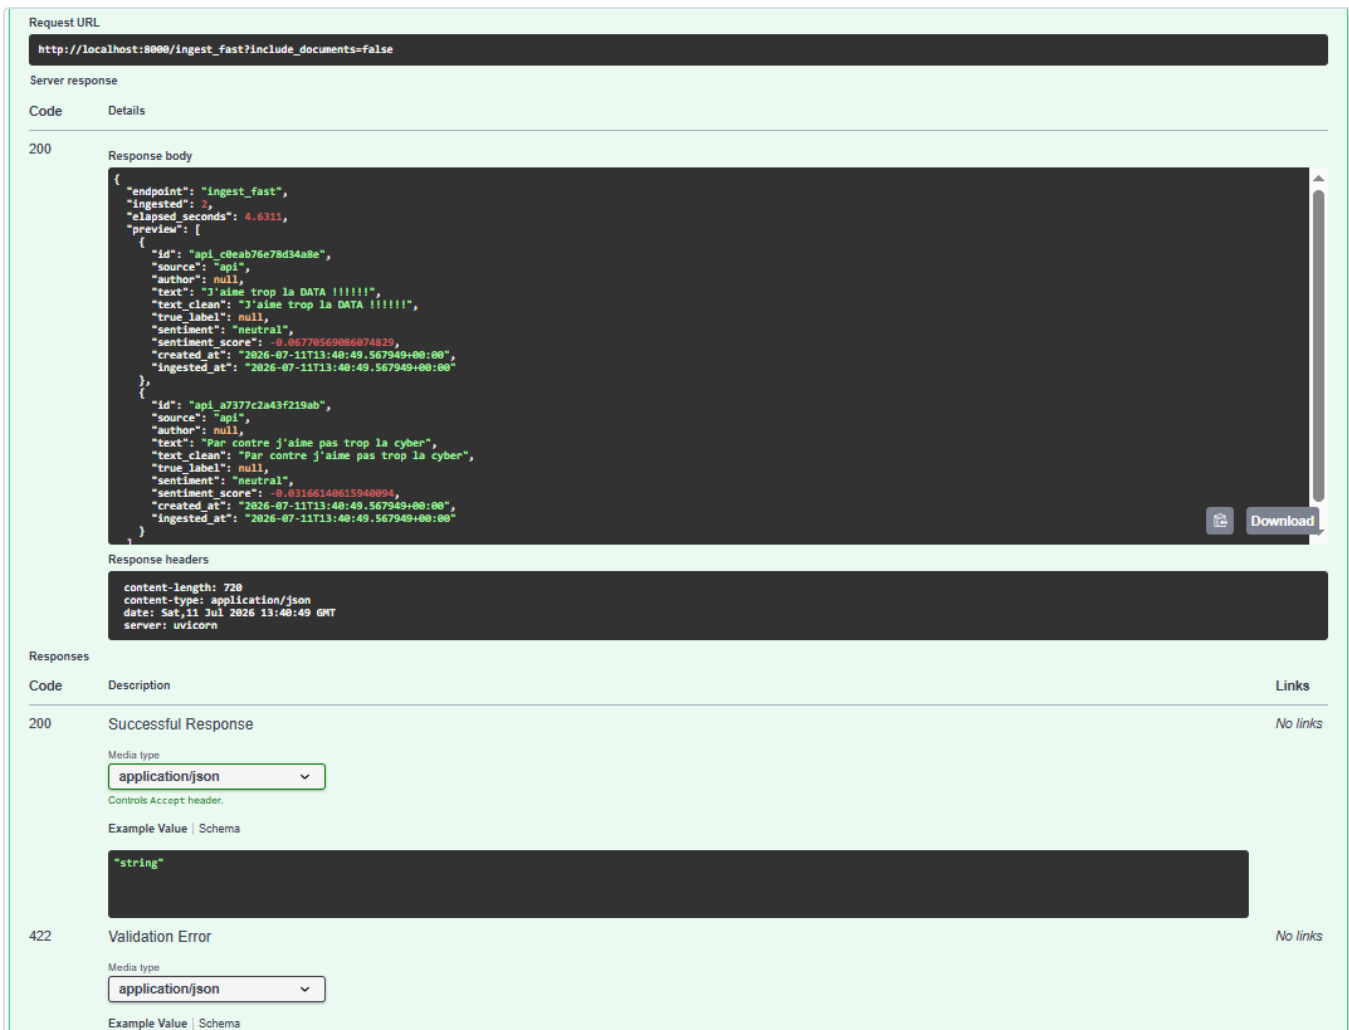


Figure 13 — Réponse : documents enrichis (sentiment, score) et `elapsed_seconds` chronométré côté serveur.

8.1 Prérequis méthodologique : l'équivalence fonctionnelle

UN BENCHMARK N'A DE SENS QUE SI LES RÉSULTATS SONT IDENTIQUES

Avant toute mesure de temps, chaque répétition vérifie que les deux endpoints produisent le même résultat : identifiants identiques, **labels de sentiment rigoureusement identiques**, scores coïncidant à $1e-5$ près.

Pourquoi une tolérance et non une égalité stricte ? En mode *batch*, les textes sont complétés (*padding*) à une longueur commune et les multiplications matricielles s'exécutent dans un ordre différent. Or l'addition en virgule flottante n'est **pas associative** : $(a+b)+c \neq a+(b+c)$ au bit près. L'écart observé, de l'ordre de $1e-7$, est un bruit numérique inhérent au batching — et non un défaut de correction.

8.2 Optimisations mises en œuvre

#	Optimisation	Principe et effet
1	Inférence par lots	Le gain dominant. L'implémentation naïve effectue N passes du Transformer ; la version optimisée empile les N textes dans un seul tenseur et exploite les multiplications matricielles vectorisées. Une seule passe.
2	Indexation <code>_bulk</code>	Un unique aller-retour HTTP vers Elasticsearch au lieu de N indexations unitaires.
3	Écritures S3 parallèles	Les N écritures en zone RAW sont indépendantes et limitées par les entrées/sorties : un pool de threads les recouvre.
4	Recouvrement I/O ↔ calcul	Les écritures RAW ne dépendent pas du scoring : elles sont lancées en tâche de fond <i>pendant</i> l'inférence. Leur coût devient quasi invisible.
5	Pool de threads partagé	Instancié une seule fois pour le processus (voir encadré ci-dessous).

Trois optimisations complémentaires ont été appliquées dans les **couches communes** — `torch.inference_mode()` (+16 % sur l'inférence), mise en cache des clients S3 et Elasticsearch, et passage du *translog* Elasticsearch en mode asynchrone (+21 % sur les écritures). Elles bénéficient aux **deux** endpoints et ne faussent donc pas la comparaison.

UN BUG DE PERFORMANCE DÉCOUVERT PAR LA MESURE

Une première campagne a révélé que `/ingest_fast` était **plus lent** que `/ingest` sur un batch de 1 (–16 %). L'analyse a identifié deux causes, toutes deux issues de notre propre code : le pool de threads était **recréé à chaque requête**, et l'indexation *bulk* déclenchait un `refresh` séparé, soit deux allers-retours HTTP au lieu d'un. Après correction (pool partagé, `refresh` intégré à la requête *bulk*), le gain à N=1 est redevenu positif. **Sans mesure systématique, une « optimisation » qui dégrade les performances serait passée inaperçue.**

8.3 Protocole de mesure

1. **Warm-up** — le modèle (~500 Mo) est chargé paresseusement à la première inférence (~25 s). Deux appels préalables l'excluent de la mesure.
2. **Textes uniques** — chaque répétition emploie des textes distincts, afin qu'aucun cache ne favorise l'endpoint exécuté en second.
3. **Alternance et médiane** — l'ordre d'exécution est inversé à chaque répétition ; la médiane, robuste aux valeurs aberrantes, est préférée à la moyenne.
4. **Mesure côté serveur** — le chronomètre entoure le pipeline lui-même, hors sérialisation JSON et latence réseau.

8.4 Résultats

```
=====
SYNTHÈSE
=====
batch  1 : naive  0.1614s -> fast  0.1100s | gain +31.8% | x1.5 | équivalence OK
batch  2 : naive  0.2175s -> fast  0.1176s | gain +45.9% | x1.8 | équivalence OK
batch  5 : naive  0.4755s -> fast  0.1745s | gain +63.3% | x2.7 | équivalence OK
batch 10 : naive  0.9927s -> fast  0.2567s | gain +74.1% | x3.9 | équivalence OK
batch 25 : naive  2.3459s -> fast  0.5000s | gain +78.7% | x4.7 | équivalence OK
batch 50 : naive  4.9024s -> fast  0.8950s | gain +81.7% | x5.5 | équivalence OK
batch 100 : naive 10.0249s -> fast  1.6840s | gain +83.2% | x6.0 | équivalence OK

Objectif >= 30% : ATTEINT
```

Figure 14 — Synthèse du benchmark. L'objectif de 30 % est atteint sur **toutes** les tailles de batch, l'équivalence fonctionnelle étant vérifiée à chaque mesure.

Batch	/ingest	/ingest_fast	Gain	Accélération	Équivalence
1	0,1614 s	0,1100 s	+31,8 %	×1,5	OK
2	0,2175 s	0,1176 s	+45,9 %	×1,8	OK
5	0,4755 s	0,1745 s	+63,3 %	×2,7	OK
10	0,9927 s	0,2567 s	+74,1 %	×3,9	OK
25	2,3459 s	0,5000 s	+78,7 %	×4,7	OK
50	4,9024 s	0,8950 s	+81,7 %	×5,5	OK
100	10,0249 s	1,6840 s	+83,2 %	×6,0	OK

8.5 Analyse : pourquoi le gain croît avec la taille du batch

La progression du gain (+31,8 % à N=1, +83,2 % à N=100) n'est pas fortuite : elle est la signature directe de la **loi d'Amdahl**. Le profilage du pipeline sur un texte unique en donne la clé :

Étape	Temps médian	Compressible à N=1 ?
Indexation Elasticsearch (1 document)	≈ 56 ms	Non — un aller-retour HTTP incompressible
Inférence RoBERTa (1 texte)	≈ 46 ms	Non — coût fixe du modèle
Écriture S3 (zone RAW)	≈ 12 ms	Oui — recouverte par le calcul
Divers	≈ 4 ms	Marginal

Sur un texte unique, environ **90 % du temps est un coût fixe** que ni le *batching* ni le parallélisme ne peuvent réduire : il n'y a qu'un texte à traiter et qu'un document à écrire. L'accélération est donc **bornée par la fraction non parallélisable** du travail. À mesure que le batch grandit, cette fraction devient marginale et le gain converge vers un facteur 6.

Le résultat à N=1 (+31,8 %) est par ailleurs le plus **variable** d'une campagne à l'autre — nous avons mesuré des valeurs comprises entre +15 % et +32 %. C'est cohérent : les écarts y sont de l'ordre de quelques dizaines de millisecondes, donc très sensibles au bruit de mesure. Le cas d'usage réel d'une API d'ingestion étant le traitement par lots, c'est sur ce régime que la solution doit être jugée — et le gain y est massif et stable.

8.6 Une optimisation testée puis rejetée : la quantification int8

Pour tenter de réduire le coût fixe du modèle, nous avons évalué la **quantification dynamique int8** (remplacement des poids flottants 32 bits par des entiers 8 bits sur les couches linéaires). Les mesures ont été sans appel :

- **Vitesse** : environ **2,5 fois plus lente** (111 ms contre 43 ms sur un texte) — les noyaux int8 de PyTorch ne sont pas optimisés pour cette architecture CPU ;
- **Fidélité** : seulement **85,5 %** d'accord de labels avec le modèle d'origine, l'écart de score atteignant 0,70.

L'optimisation a donc été **écartée : plus lente et moins fidèle**. Nous la documentons délibérément, car une démarche d'ingénierie se juge autant à ce qu'elle rejette, sur preuves, qu'à ce qu'elle retient.

8.7 Pourquoi Numba n'a pas été retenu

Le sujet suggère Numba, qui compile en code machine les boucles Python opérant sur des tableaux NumPy. Le profilage montre qu'il serait ici **sans effet** : le goulot d'étranglement n'est pas une boucle numérique en Python, mais **(a)** l'inférence d'un réseau de neurones — déjà exécutée par le noyau C++/ATen optimisé de PyTorch — et **(b)** les entrées/sorties réseau vers S3 et Elasticsearch. Optimiser ce qui n'est pas le goulot d'étranglement ne produit aucun gain. Nous avons donc ciblé le **batching** et le **parallélisme d'I/O**, là où le temps se trouve réellement.

9. Difficultés rencontrées et résolues

Ces incidents, tous diagnostiqués et corrigés, illustrent la réalité de la mise au point d'une chaîne de données.

Difficulté	Diagnostic	Résolution
Fermeture de l'API Reddit	La plateforme a supprimé la création d'applications <i>legacy</i> en cours de projet.	Bascule vers Hacker News. Grâce au découplage de la couche d'ingestion, un seul fichier a été modifié.
Conflit de DLL sous Windows	PyTorch et PyArrow embarquent chacun un runtime OpenMP (<code>libiomp5md.dll</code>). Chargé en second, PyTorch échoue à initialiser <code>c10.dll</code> . Hypothèse validée par test d'inversion de l'ordre d'import.	Module dédié <code>torch_first.py</code> , importé en tête des points d'entrée, qui rend la contrainte explicite et documentée plutôt qu'implicite.
Permissions du volume Airflow	Le volume de cache du modèle était créé sous <code>root</code> , alors qu'Airflow s'exécute sous l'UID 50000 → <code>PermissionError</code> .	<code>chown</code> du répertoire dans l'image, Docker initialisant le volume avec le propriétaire du dossier de l'image.
Dépendances et Python 3.13	Absence de <i>wheels</i> précompilés pour une version de Python très récente.	Montée de version ciblée de <code>pyarrow</code> et <code>numba</code> .
<code>bulk</code> plus lent que l'indexation unitaire	Sur un batch de 1, notre <code>bulk_index</code> (74 ms) dépassait <code>es.index</code> (56 ms) : un <code>refresh</code> séparé provoquait deux allers-retours HTTP.	<code>refresh=True</code> intégré à la requête <i>bulk</i> .
Effet de bord global	L'accesseur du modèle appelait <code>torch.set_grad_enabled(False)</code> , mutant l'état de tout le processus .	Remplacement par un <code>torch.inference_mode()</code> de portée locale, au moment du calcul.

10. Limites et perspectives

10.1 Le modèle est monolingue

LIMITE IDENTIFIÉE EN TEST

Le modèle `twitter-roberta-base-sentiment-latest` est entraîné sur des tweets **en anglais**. Soumis à des textes français, il les classe systématiquement en *neutral* avec un score proche de zéro : il n'y détecte aucun signal (visible en figure 13). Ce n'est pas un défaut du pipeline — qui traite correctement le texte — mais une **limite du modèle choisi**, à connaître avant tout déploiement sur des données francophones.

Correction possible : substituer `cardiffnlp/twitter-xlm-roberta-base-sentiment`, variante multilingue du même modèle. L'architecture le permet **sans aucune modification de code** : le nom du modèle est une variable d'environnement (`SENTIMENT_MODEL`).

10.2 Autres limites et pistes d'évolution

Limite	Piste d'amélioration
Re-traitement intégral en staging	Le pipeline RAW→STAGING relit l'ensemble de la zone brute à chaque cycle. Acceptable à cette volumétrie, mais coûteux à l'échelle. Un traitement <i>incrémental</i> (ne lire que les partitions postérieures au dernier instantané) serait la suite naturelle.
Absence de tests automatisés	La validation a été empirique (exécution réelle de chaque étape). Une suite <code>pytest</code> couvrant les normaliseurs et le nettoyage sécuriserait les évolutions futures.
Sécurité désactivée	Elasticsearch tourne sans authentification et l'API est ouverte : acceptable pour un déploiement local, à proscrire en production (TLS, authentification, secrets gérés hors <code>.env</code>).
Inférence sur CPU	Le débit plafonne à environ 60 textes/seconde. Un portage GPU ou un modèle distillé (<i>DistilRoBERTa</i>) offrirait un ordre de grandeur supplémentaire.
Aucune couche de visualisation	Les données curated se prêtent naturellement à un tableau de bord Kibana (évolution du sentiment dans le temps, détection de signaux faibles).

11. Conclusion

Le data lake réalisé couvre l'intégralité du périmètre demandé, niveau avancé compris. Deux sources hétérogènes sont ingérées, unifiées dans un schéma commun, enrichies par un modèle de Deep Learning atteignant **75,6 % de précision**, puis exposées via neuf endpoints. L'ensemble est orchestré par Airflow, entièrement conteneurisé, et démarre par une commande unique. L'endpoint optimisé atteint **+83,2 % de gain** ($\times 6,0$), très au-delà des 30 % exigés, avec une équivalence fonctionnelle vérifiée à chaque mesure.

Au-delà des livrables, ce projet aura surtout été l'occasion d'appliquer une **méthode**. À chaque obstacle — précision décevante de VADER, gain insuffisant à faible batch, régression de performance inattendue, conflit de bibliothèques — la même séquence a été suivie : *mesurer, comprendre, décider, documenter*. C'est cette discipline qui a permis d'identifier un bug de performance dans notre propre code d'optimisation, de rejeter la quantification int8 sur preuves plutôt que par principe, et d'assumer les limites du modèle au lieu de les dissimuler.

CE QUE LE PROJET DÉMONTRE

Un data lake ne se juge pas seulement à l'empilement de ses technologies, mais à la **rigueur des décisions** qui les relient — et à la capacité à prouver, chiffres à l'appui, que chacune était la bonne.

```
be5caf9 (HEAD -> main) Correctifs benchmark : erreur de syntaxe + pool de threads partage
73ecf10 (origin/main) Phase 8 : conteneurisation de l'API + documentation
1064d6e Phase 7 : niveau avance /ingest et /ingest_fast + benchmarks
be1de45 Phase 6 : API Gateway FastAPI
e7f8d34 Phase 5 : orchestration Apache Airflow
7a63dfa Phase 4 : zone CURATED avec sentiment Deep Learning
047f636 Phase 3 : transformation RAW -> STAGING
1b889cb Phases 1-2 : infra + ingestion vers RAW
39d851c Phase 0 : scaffolding du data lake
```

Figure 15 — Historique du dépôt : un commit par phase, du scaffolding aux correctifs de performance.

Annexe A — Installation et build

Prérequis

- Docker Desktop (Compose v2) — environ 6 Go de RAM et 5 Go de disque

Démarrage complet

```
cp .env.example .env
docker compose up -d --build
```

Au premier lancement, la construction des images et le téléchargement du modèle (~500 Mo, mis en cache ensuite) requièrent quelques minutes.

Service	URL	Identifiants
API (documentation)	<code>http://localhost:8000/docs</code>	—
Airflow	<code>http://localhost:8080</code>	<code>admin / admin</code>
MinIO (console)	<code>http://localhost:9001</code>	<code>minioadmin / minioadmin123</code>
Elasticsearch	<code>http://localhost:9200</code>	—

Alimenter le lac

Le DAG s'exécute automatiquement toutes les heures. Déclenchement immédiat :

```
docker exec dl_airflow_scheduler airflow dags trigger datalake_pipeline
```

Rejouer le benchmark

```
python -m venv .venv && .venv\Scripts\activate
pip install -r requirements.txt
pip install torch --index-url https://download.pytorch.org/whl/cpu

python scripts/benchmark.py --sizes 1 2 5 10 25 50 100
```

Le script régénère `docs/performance.md` avec les mesures obtenues.

Annexe B — Structure du dépôt

```
src/
  common/          code transverse
    config.py      configuration centralisée (variables d'environnement)
    s3_client.py   accès MinIO / S3 (zones raw et staging)
    es_client.py   accès Elasticsearch (zone curated)
    nlp.py         nettoyage de texte + moteurs de sentiment (VADER, RoBERTa)
    torch_first.py contournement du conflit de DLL Windows
  ingestion/
    hackernews_api.py source API
    load_dataset.py   source fichier (HuggingFace)
  transform/
    raw_to_staging.py  nettoyage + unification des schémas
    staging_to_curated.py scoring de sentiment + indexation + évaluation
  api/
    main.py          endpoints FastAPI
    ingest.py        pipeline d'ingestion à la demande (naïf et optimisé)

airflow/dags/
  datalake_dag.py   DAG d'orchestration

docker/             Dockerfiles Airflow et API
scripts/
  benchmark.py      campagne de mesure (génère docs/performance.md)
docs/
  architecture.md  documentation technique
  performance.md   résultats de performance (généré)
```

Code source complet, documentation technique et résultats détaillés dans le dépôt du projet.